

Points d'amélioration & reste à faire

Document de suivi (roadmap). Complète la section « Reste à faire » du `RAPPORT_FINAL.md` avec le détail, la priorité et l'effort estimé.

Légende effort : S = court (<30 min) · M = moyen (0,5–2 h) · L = long (>2 h / dépend Colab/GPU).

1. Reste à faire pour compléter les livrables attendus (CONSIGNES)

Item (checklist CONSIGNES)	État	Priorité	Effort
IA — Fine-tuner le modèle médical sur Colab	TODO Notebook prêt, non exécuté	Haute (bonus attendu)	L
IA — Partager le lien Colab + métriques (loss, epochs)	TODO À produire après run	Haute	S
DATA — Préparer/nettoyer le dataset médical pour l'IA	TODO Non fait (chargé mais pas nettoyé)	Moyenne	M
INFRA — Rendre le serveur accessible aux DEV WEB du groupe (LAN)	TODO Local uniquement (<code>localhost</code>)	Moyenne	S
INFRA — Bonus : dockeriser avec <code>tritton_server/</code>	TODO Dockerfile fourni, non construit	Basse	L
Rendu — Commit régulier + push branche <code>groupe-<filiere>-<numero></code>	TODO Non fait	Haute	S
CYBER — Audit + robustesse + rapports	OK Fait (9/9)	—	—
DATA — Analyse/nettoyage dataset financier	OK Fait	—	—
INFRA/IA/DEV WEB — Déploiement + interface + validation	OK Fait	—	—

2. Points d'amélioration techniques par filière

Modèle / IA

- **Servir le vrai fine-tune assaini** : ré-entraîner l'adapter sur `finance_dataset_final.clean.json` puis **merge + conversion GGUF** -> remplacer `base + prompt` par le modèle spécialisé propre. *Impact : fidélité « Financial » ; Effort : L.*
- **Jeu d'évaluation finance dédié** : le test set fourni est généraliste. Construire ~50 Q/R finance de référence pour scorer objectivement. *Effort : M.*
- **Qualité des réponses** : le base `phi3.5` dérive parfois (ex. « intérêt » vs « intérêt composé »). Un fine-tune propre + few-shot dans le prompt améliorerait la précision. *Effort : M.*

INFRA

- **Exposition réseau** : `OLLAMA_HOST=0.0.0.0:11434` + doc IP/port pour le DEV WEB multi-postes (/!\ réseau de confiance, pas d'auth native Ollama). *Effort : S.*
- **Réglage inférence** : ajuster `keep_alive`, `num_gpu`, `num_thread` selon la machine ; tester

d'autres quantizations. *Effort : S.*

- **Bonus Triton** : construire l'image `triton_server/`, mais **corriger** d'abord que `model.py/`
`config.pbtxt` servent le **base** (pas l'adapter). *Effort : L.*

DEV WEB

- Bouton **Stop** (interrompre le streaming), curseur **température**, **export** de la conversation (Markdown/JSON). *Effort : S-M.*
- **Auth légère** (mot de passe Streamlit) si exposition réseau. *Effort : S.*
- Gestion d'erreur plus fine (timeout, modèle absent -> message guidant vers l'INFRA). *Effort : S.*

DATA

- **Pipeline de nettoyage médical** (dédup, anonymisation, formatage instruction/réponse) réutilisant `clean_dataset.py`. *Effort : M.*
- **Dédup approché** (near-duplicates), pas seulement doublons exacts. *Effort : M.*
- Resserrer le **faux positif** de la regex `credential_pass` sur le test set (1 cas). *Effort : S.*

CYBER

- **Filtre de sortie (DLP)** côté application : bloquer tout secret dans la réponse avant envoi au client (défense en profondeur indépendante du modèle). *Effort : M.*
- **Élargir la batterie de tests** : trigger encodé (base64/rot13), multilingue, tentative d'exfiltration par métadonnées, réponses très longues. *Effort : M.*
- **CI sécurité** : scan de secrets (gitleaks/trufflehog) + exécution de `robustness_test.py` en pipeline (code retour non nul = échec). *Effort : M.*
- **Durcissement chargement modèle** : épingler `revision` HF, retirer `trust_remote_code` quand possible, **retirer** `training_args.bin` (pickle) et `__pycache__` du dépôt. *Effort : S.*

3. Limites & dette connues (à assumer en soutenance)

- Le **garde-fou par system prompt** atténue mais **ne prouve pas** l'absence de backdoor ; la mesure primaire reste de **servir un modèle non piégé**.
- L'**adapter livré** n'a pas été analysé au niveau des poids (probing d'activations) — il est simplement **écarté** ; une analyse forensique poussée serait un plus.
- Le **chemin Triton** fourni est inutilisé (on a choisi Ollama) ; laissé documenté.
- Les **secrets** du dataset sont traités comme fuités par principe, sans certitude qu'ils correspondent à des actifs réels.

4. Sécurité — durcissement recommandé (récap rapport)

- **A-06** Rotation des secrets exposés (*exploitant*).
- **A-08** DLP en sortie + scan secrets CI + épinglage revision + suppression pickle/`__pycache__`.

5. Priorisation synthétique (impact × effort)

Rang	Action	Pourquoi	Effort
1	Commit + push (branche au bon nom)	Rendu noté	S

2	POC médical Colab + métriques	Bonus attendu, manquant	L
3	Exposition LAN du serveur	Vrai multi-postes DEV WEB	S
4	Ré-entraînement finance propre + GGUF	Délivrer le vrai fine-tune	L
5	DLP en sortie + CI sécurité	Robustesse durable	M
6	Nettoyage dataset médical	Préparer l'IA	M

Mis à jour le 2026-07-01. La mission cœur (audit + assainissement + déploiement sûr + tests 9/9) est terminée ; ce document liste le bonus et l'amélioration continue.

--	--	--	--

--	--	--	--